



# 共享内存区的冲突

共享内存物理上是以区的形式存储的

。




逻辑共享内存  
`cuda.shared.array(4,4)`




物理共享内存  
分为 4 个区


Warp



实际共享内存是 32 个 4 字节宽的存储区。为了利用演示中的页面空间，我们将共享内存描述为具有 4 个存储区（A、B、C、D），而一个Warp描述为具有 4 个线程的单位。

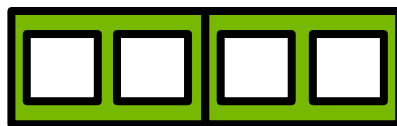


逻辑共享内存  
`cuda.shared.array(4,4)`




物理共享内存  
分为 4 个区


Warp



连续的 4 字节的字（图中的 1 个方块）  
属于不同的区。



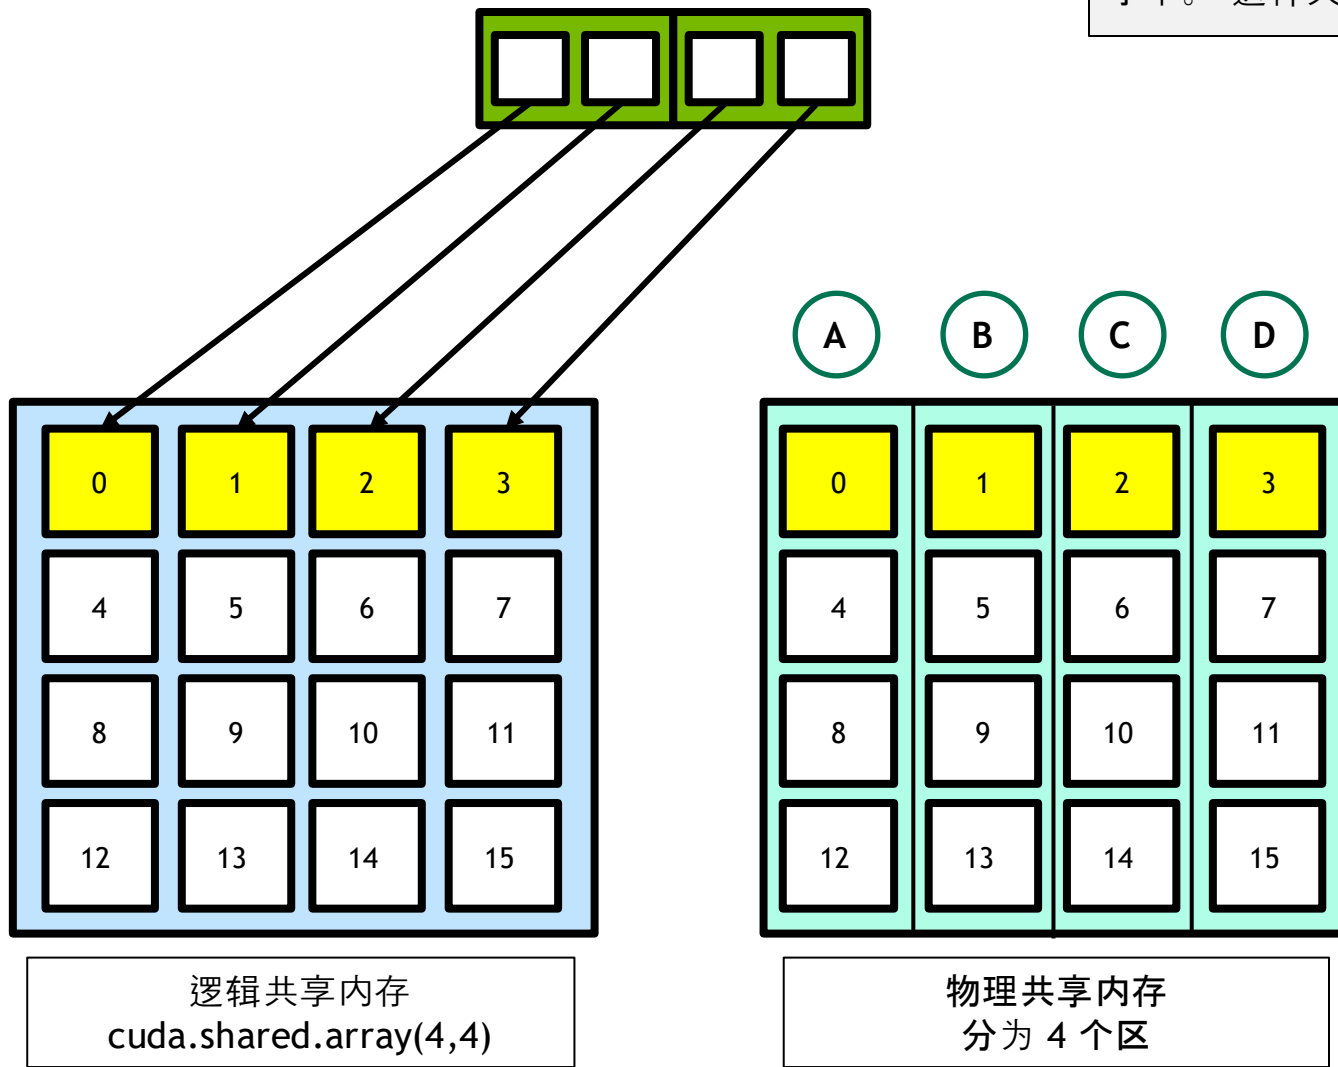
逻辑共享内存  
`cuda.shared.array(4,4)`



物理共享内存  
分为 4 个区

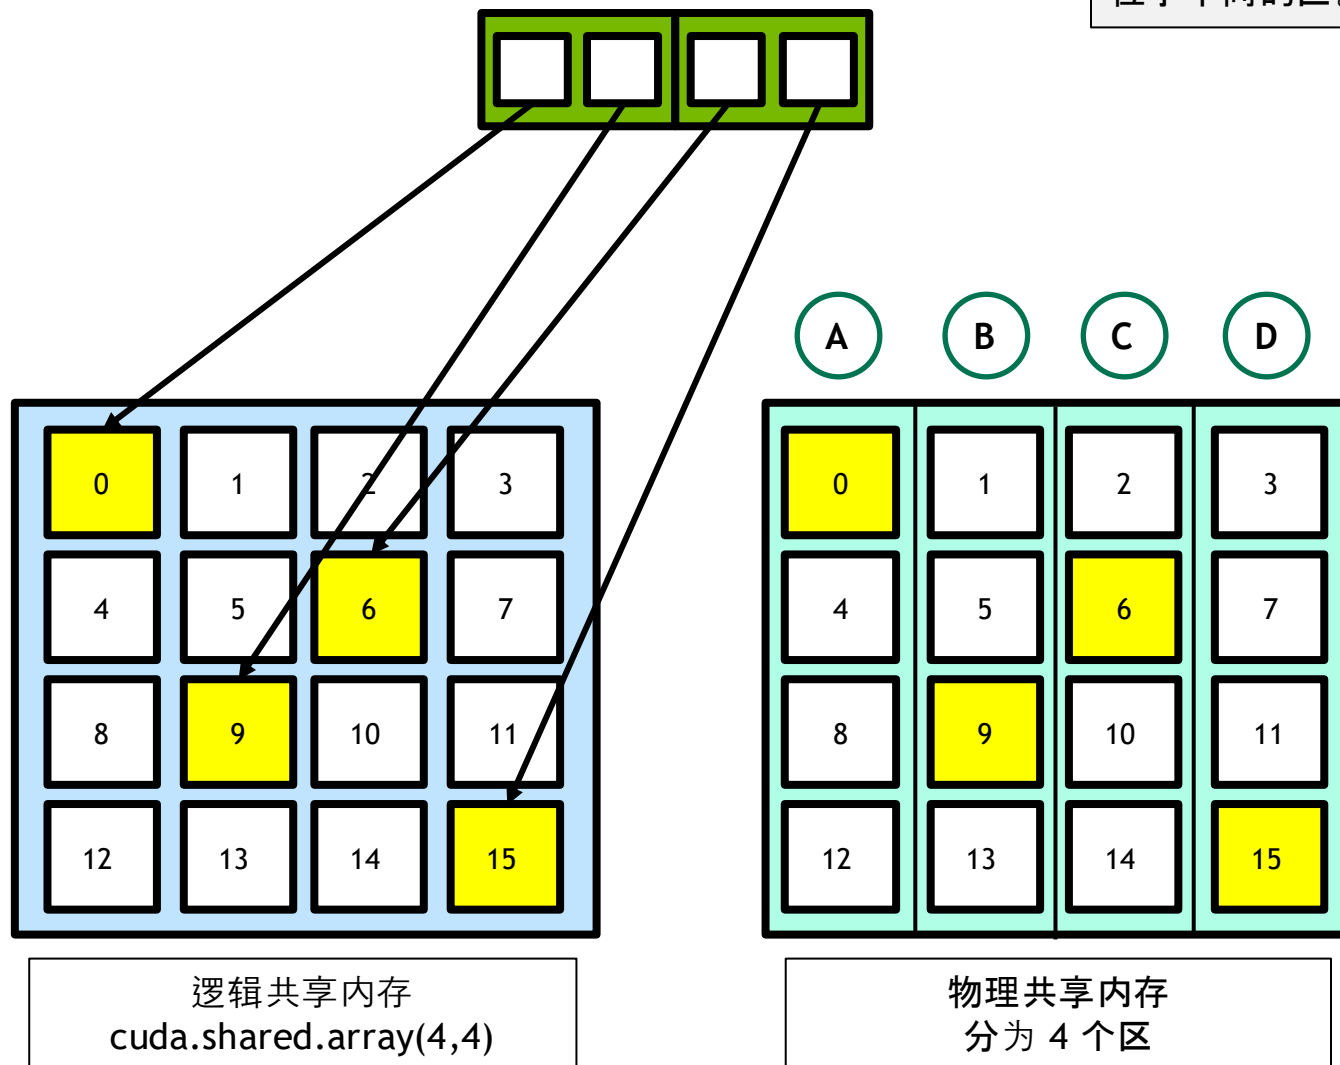
Warp

一个 warp 可以并行访问每个区的 4 个字节。这种共享内存访问将同时发生。




Warp


这个情形也是一样，因为每个数据元素位于不同的区。




Warp



对同一区中的内存进行访问会导致访问操作串行化。我们称之为**区冲突**。




逻辑共享内存  
`cuda.shared.array(4,4)`



物理共享内存  
分为 4 个区

Warp


在这种情况下，我们有一个 2-路的区冲突，需要在 2 个周期内序列化内存访问







Warp

这是一个 4-路的区冲突，需要在 4 个周期内序列化内存访问。





回想一下我们之前的矩阵转置示例，我们正在从共享内存进行这种**列式读取**，这意味着我们有严重的**区冲突**。

```
tile = cuda.shared.array(2,2)
x, y = cuda.grid(2)

tile[tldx.y][tldx.x] = in[y][x]
cuda.syncthreads()

o_x = bld.y*bDim.y + tld.x
o_y = bld.x*bDim.x + tld.y
o[o_y][o_x] = tile[tldx.x][tldx.y]
```

0	1	2	3
4	5	6	7
8	9	10	11
12	13	14	15

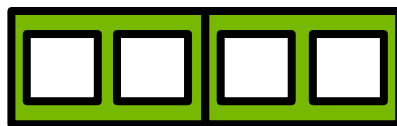
Input

0	4	8	12
1	5		


Output

当我们知道需要对共享内存进行列访问时，我们可以使用以下技术来避免冲突。

Warp




首先，当我们分配共享内存块时，我们将用额外的列填充它。




逻辑共享内存  
`cuda.shared.array(4,5)`

Warp




接下来，当我们向共享内存块写入数据时，我们就当它是 (4,4) 一样，只写入范围 [0:4][0:4] 中的地址。




逻辑共享内存  
`cuda.shared.array(4,5)`

Warp




物理共享内存的固定大小为 32 个存储区（我们的示例中使用 4 个存储区，以节省页面空间），因此我们对共享存储阵列的填充不会影响存储区的数量。




逻辑共享内存  
`cuda.shared.array(4,5)`

A B C D




物理共享内存  
分为 4 个区


Warp



因此，如果我们考虑数组在内存区中的布局，我们会看到以下情景：




逻辑共享内存  
`cuda.shared.array(4,5)`




物理共享内存  
分为 4 个区


Warp



因此，如果我们考虑数组在内存区中的布局，我们会看到以下情景：




逻辑共享内存  
`cuda.shared.array(4,5)`




物理共享内存  
分为 4 个区




Warp



因此，如果我们考虑数组在内存区中的布局，我们会看到以下情景：




逻辑共享内存  
`cuda.shared.array(4,5)`




物理共享内存  
分为 4 个区


Warp



因此，如果我们考虑数组在内存区中的布局，我们会看到以下情景：




逻辑共享内存  
`cuda.shared.array(4,5)`




物理共享内存  
分为 4 个区

Warp




现在，当我们访问一列共享内存时，每个元素都驻留在不同的区中，并且没有区冲突。



逻辑共享内存  
`cuda.shared.array(4,5)`

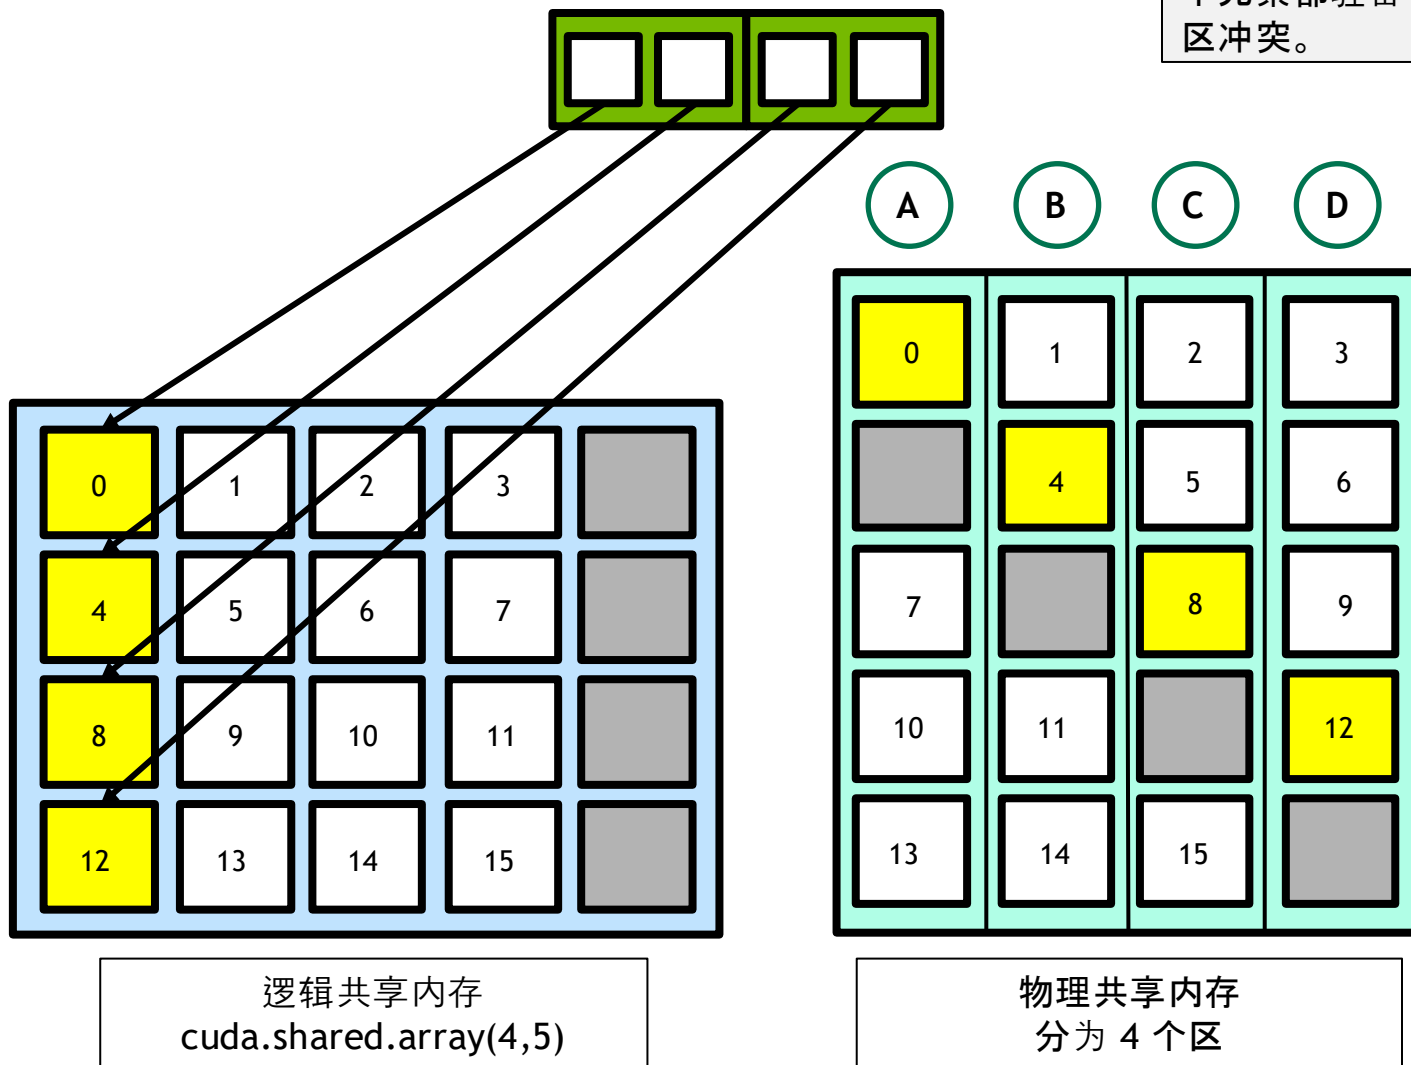
A B C D



物理共享内存  
分为 4 个区

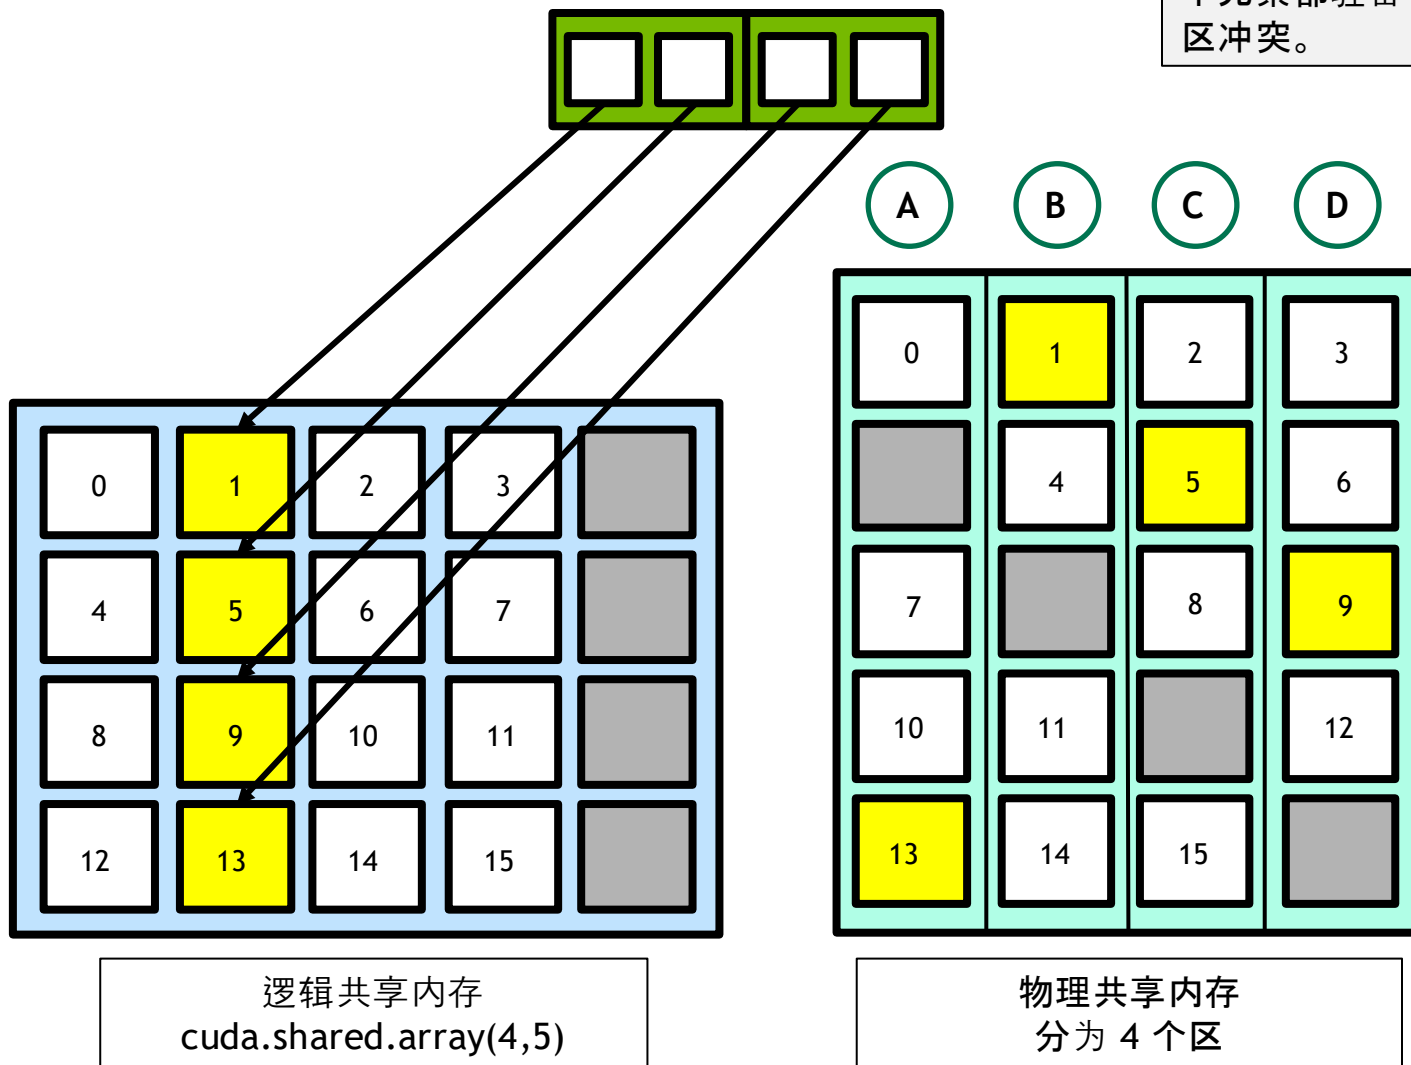
Warp

现在，当我们访问一列共享内存时，每个元素都驻留在不同的区中，并且没有区冲突。



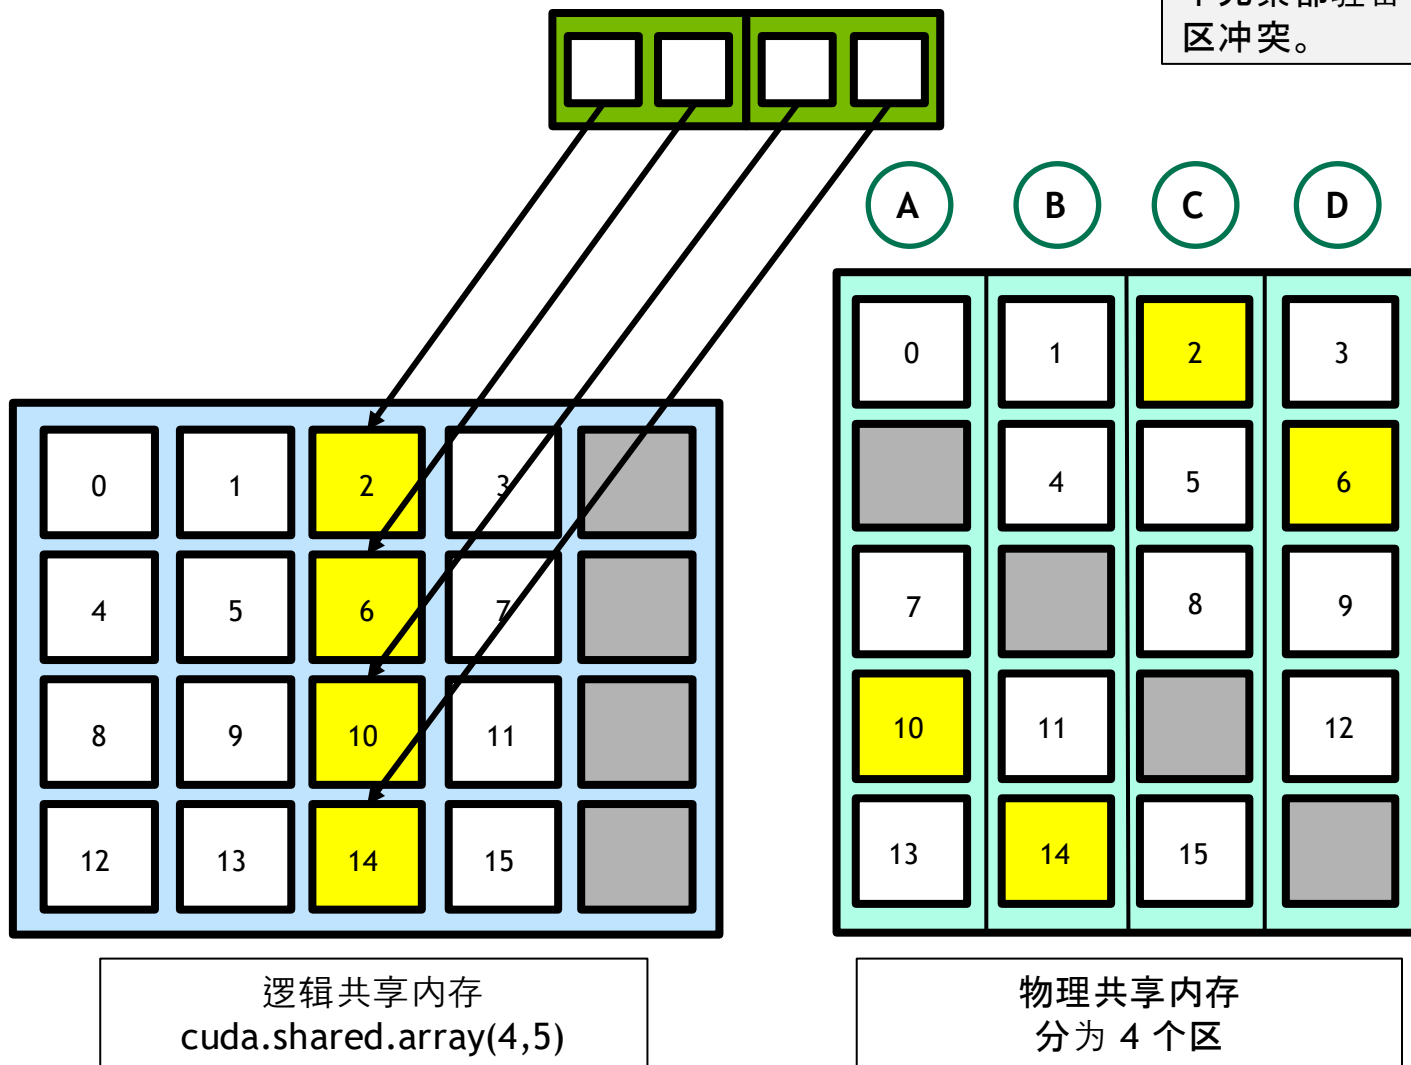
Warp

现在，当我们访问一列共享内存时，每个元素都驻留在不同的区中，并且没有区冲突。



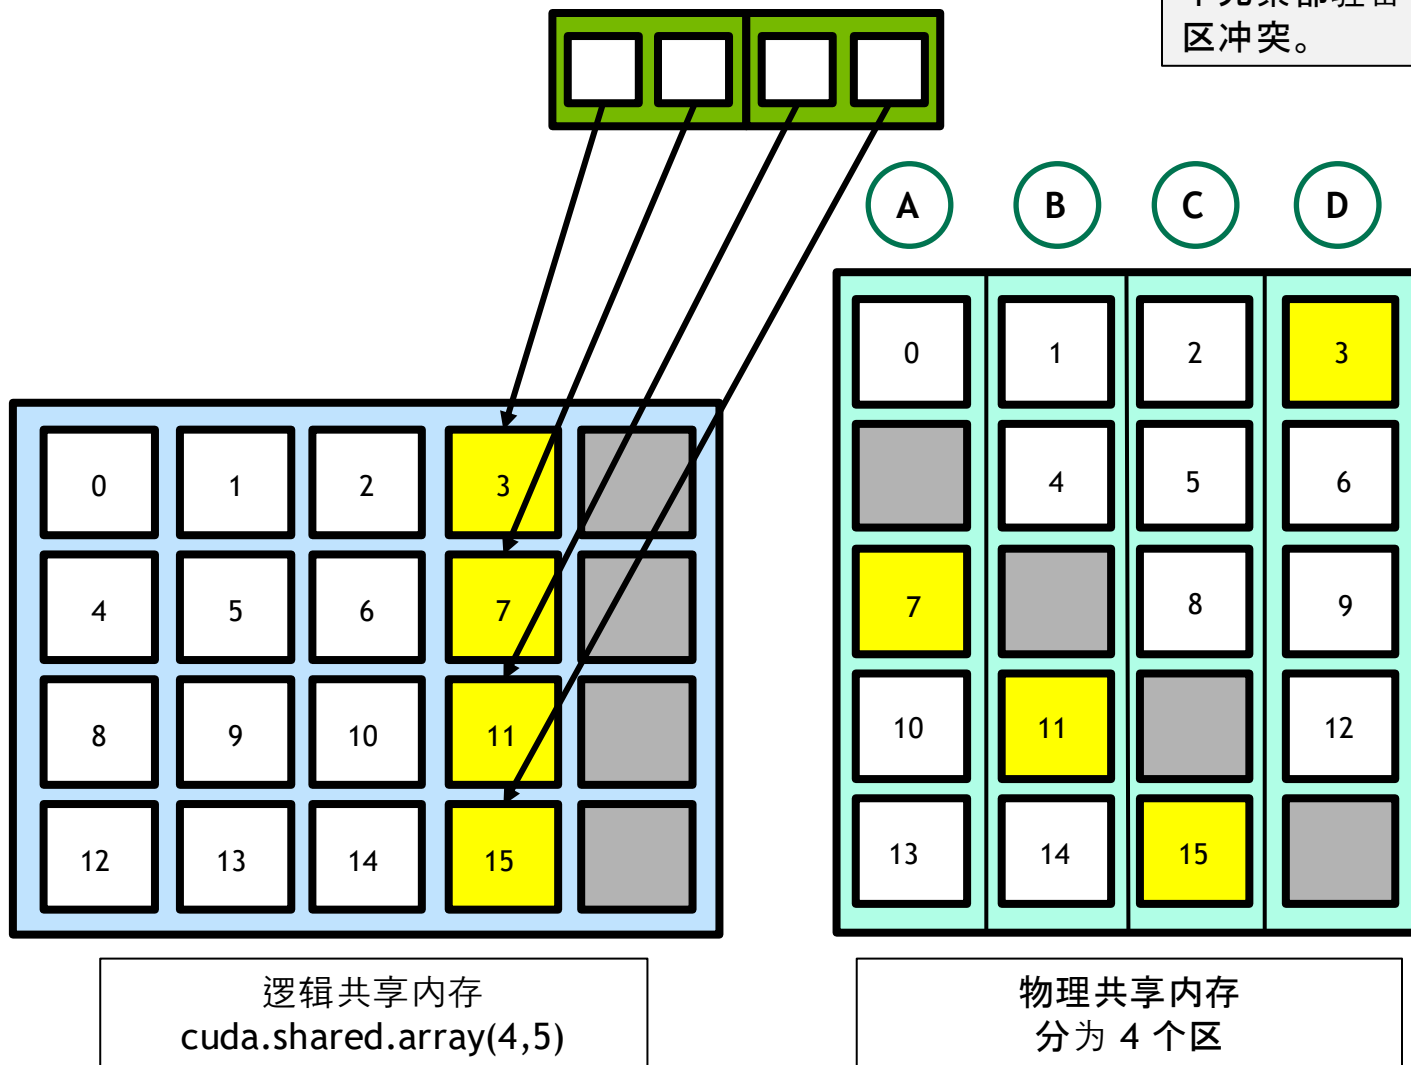
Warp

现在，当我们访问一列共享内存时，每个元素都驻留在不同的区中，并且没有区冲突。



Warp


现在，当我们访问一列共享内存时，每个元素都驻留在不同的区中，并且没有区冲突。




逻辑共享内存  
`cuda.shared.array(4,5)`

物理共享内存  
分为 4 个区

Warp




值得一提的是，要在此示例中使用此技术，我们必须对代码进行的唯一更改是在共享内存分配中添加一个额外的列。





逻辑共享内存  
`cuda.shared.array(4,5)`

A B C D



物理共享内存  
分为 4 个区





从我们之前的矩阵转置示例中，下面绿色的单个更改足以在保持正确性的同时避免区冲突。

```
tile = cuda.shared.array(2,3)
x, y = cuda.grid(2)

tile[tldx.y][tldx.x] = in[y][x]
cuda.syncthreads()

o_x = bld.y*bDim.y + tld.x
o_y = bld.x*bDim.x + tld.y
o[o_y][o_x] = tile[tldx.x][tldx.y]
```

0	1	2	3
4	5	6	7
8	9	10	11
12	13	14	15

输入

0	4	8	12
1	5	9	13
2	6	10	14
3	7	11	15

输出



DEEP  
LEARNING  
INSTITUTE

学习更多课程, 请访问 [www.nvidia.cn/DLI](http://www.nvidia.cn/DLI)

